

¿Qué es el machine learning?

Machine learning

Le damos la bienvenida

▼ Introducción

Visión general

Tipos de machine learning

Algoritmos de machine learning

- ▶ Ciencia de datos para machine learning
- ▶ Ingeniería de características
- ▶ Aprendizaje supervisado
- ▶ Aprendizaje no supervisado
- ▶ Aprendizaje semisupervisado
- ▶ Aprendizaje de refuerzo
- ▶ Deep learning
- ▶ Generative AI
- ▶ Entrenamiento de modelos
- ▶ Bibliotecas de machine learning
- ▶ MLOps
- ▶ Procesamiento del lenguaje natural
- ▶ Visión artificial



Autor**Dave Bergmann**

Senior Staff Writer, AI Models
IBM Think

¿Qué es el machine learning?

El machine learning es el subconjunto centrado en algoritmos que pueden "aprender" de entrenamiento y, posteriormente, hacer predicciones sobre nuevos datos. Esta capacidad de reconocer patrones en nuevos datos es lo que permite a los modelos de machine learning tomar decisiones basadas en instrucciones explícitas y codificadas.

El machine learning ha llegado a dominar el campo central de la mayoría de los sistemas modernos, desde vehículos autónomos, pasando por [modelos de IA generativa](#).

La premisa central del ML es que si se optimiza un modelo con datos de tareas que se asemejan a las que se utilizará, a través de un proceso llamado entrenamiento, se puede hacer predicciones precisas sobre los nuevos datos.

El entrenamiento es simplemente un medio para la capacidad de traducir un buen rendimiento en los escenarios del mundo real. Este es el objetivo esencial, un modelo entrenado aplica patrones aprendidos para inferir el output correcto para una tarea de [de IA](#) es por lo tanto llamada [inferencia de IA](#).

[El deep learning](#), el subconjunto del machine learning [neuronales artificiales](#), o más bien "profundas", arquitectura de modelos de IA de última generación utiliza la IA. A diferencia de los algoritmos explícitos tradicionales, el deep learning se basa en "redes" que le confieren una capacidad sin igual para aprender tareas complejas. Dado que el deep learning requiere recursos computacionales, su llegada ha coincidido con la de las [unidades de procesamiento gráfico \(GPU\)](#).

La disciplina del machine learning está estrechamente ligada a los [datos](#). En cierto sentido, el machine learning utiliza algoritmos y técnicas para automatizar el análisis y aplicar los aprendizajes de ese análisis a la ejecución de nuevas tareas.

Aunque el concepto central no se le atribuye a una sola persona, en 1959, publicó en la revista IBM Journal el artículo "Using the Game of Checkers" ("Algunos estudios sobre el juego de damas"). En la introducción del artículo, Samuel escribió: "un ordenador puede programarse para jugar a las damas que la propia persona que escribió el programa."

Machine learning vs. intel

Aunque "machine learning" e "inteligencia artificial" son del todo sinónimos. En resumen: *todo el machine learning es inteligencia artificial*.

En la imaginación popular, la "IA" suele asociarse con representaciones de lo que se denomina más popularmente como HAL 9000 en *2001: Una odisea en el espacio* o con [IA generativa](#). Pero "inteligencia artificial" e



Únase a los más de 100 leen las últimas noticias

Manténgase al día sobre las tendencias más im
de IA, automatización, datos y mucho más con
semana. Consulte la [Declaración de privacidad](#)

Nombre *

Apellidos *

Correo corporativo *

El contenido de su suscripción se enviará en inglés. E
cancelar su suscripción. Consulte nuestra [Declaració](#)
información.

Suscríbase



Cómo funciona el ma

El machine learning funciona a través de la lógi
relevantes de cada punto de datos deben expre
en un algoritmo matemático que "aprenderá" a
deseado.

Los puntos de datos en el machine learning sue cada elemento (o dimensión) del [embedding ve](#) valor numérico para una característica específic intrínsecamente numéricas, como los datos fina es relativamente sencillo. Pero muchas modali gráficos de redes sociales o comportamientos c intrínsecamente numéricos y, por lo tanto, impl intuitiva de inmediato para expresarse de una n

El proceso (a menudo manual) de elegir qué as machine learning se denomina [selección de car](#) [características refinan los datos hasta sus dime](#) son subconjuntos de la [ingeniería de característi](#) preprocesamiento de datos sin procesar para si notable del deep learning es que normalmente parte del proceso de ingeniería de característic: características. Esto hace que el deep learning : interpretable, que el machine learning tradicion

Parámetros y optimización learning

A modo de ejemplo, consideremos un algoritmo precio de venta de una vivienda en función de u superficie, antigüedad y número de dormitorios vectorial con 3 dimensiones: [square footage, dormitorios y 175 m² podría representarse com matemáticos, esos números podrían escalarse uniforme).

El algoritmo es una función matemática sencilla

```
Precio = (A * metros cuadrados) + (B * número base
```

Aquí, A , B y C son los parámetros del modelo tiene el modelo para cada variable. El objetivo c óptimos para dichos parámetros del modelo: er que dan como resultado que la función general mayoría de las instancias reales de machine lea



un mayor número de variables de entrada, el número de parámetros ajustables del algoritmo para obtener

Tipos de machine learning

Todos los métodos de machine learning pueden clasificarse en tres tipos de aprendizaje distintos: aprendizaje supervisado, aprendizaje no supervisado, y aprendizaje por refuerzo, en función de la naturaleza de sus objetivos (y siempre) del tipo de datos de entrenamiento que se utilizan.

- **El aprendizaje supervisado** entrena un modelo para predecir una salida dada una entrada determinada. Se aplica a tareas que tienen una relación con alguna "verdad fundamental" e implican la comparación de los outputs.
- **El aprendizaje no supervisado** entrena un modelo para descubrir dependencias y correlaciones en los datos. Las tareas de aprendizaje no supervisado no implican la comparación de los outputs.
- **El aprendizaje por refuerzo (RL)** entrena un modelo para tomar una acción que obtendrá la mayor recompensa. No hay una verdad fundamental singular, pero sí recompensas "buenas" (o neutrales).

El proceso de entrenamiento integral para un modelo a menudo lo hace, enfoques híbridos que aprovechan el aprendizaje. Por ejemplo, el aprendizaje no supervisado se utiliza para descubrir patrones en los datos para su uso en el aprendizaje supervisado. Los modelos de gran tamaño (LLM) suelen someterse a su entrenamiento a través de variantes del aprendizaje supervisado y técnicas de RL como el **aprendizaje por refuerzo**.

En una práctica similar pero distinta, varios modelos se combinan los outputs de múltiples algoritmos.

Aprendizaje supervisado

Los algoritmos de aprendizaje supervisado entrenan un modelo para predecir una salida dada una entrada, como la **clasificación** o la regresión. El



los modelos de deep learning de última generación, los modelos tradicionales de ML que aún se emplean ampliamente.

- Los modelos de **regresión** predicen valores como la temperatura o el tamaño. Algunos ejemplos son la **regresión lineal**, la regresión polinomial y los modelos de regresión logística.
- Los modelos de **clasificación** predicen el valor que pertenece un punto de datos, una decisión a tomar. Algunos ejemplos de algoritmos de clasificación son los **vectores de soporte** (SVM), el modelo **Naïve Bayes** y los árboles de decisión.
- Muchos algoritmos de ML se pueden utilizar para tareas de clasificación. El output de un algoritmo de regresión puede ser utilizado para la predicción de clasificación.

Para medir y optimizar la precisión, los outputs se comparan con la *verdad fundamental*: el output ideal o "correcto" que se obtiene de un aprendizaje supervisado convencional, esa verdad fundamental son los datos etiquetados. Un modelo de detección de spam se entrena con un conjunto de datos de correos electrónicos que ya han sido etiquetados como spam o no spam. Un modelo de **segmentación de imágenes** se entrena con un conjunto de imágenes donde cada píxel individual ha sido anotado por su clasificación. El objetivo del aprendizaje supervisado es ajustar los parámetros del modelo hasta que su output se acerque lo más posible a la verdad fundamental que proporcionan esas etiquetas.

Esencial para el aprendizaje supervisado es el concepto de divergencia ("pérdida") entre el output del modelo y el output de las entradas de entrenamiento. El objetivo del aprendizaje supervisado es *minimizar el output de pérdida*, se utilizan varios algoritmos de optimización basados en el cálculo de la/s **derivada**/s de la función de pérdida para reducir la pérdida.

Debido a que este proceso tradicionalmente requiere la verdad fundamental en forma de anotaciones de "supervisado". Como tal, el uso de datos etiquetados es una característica definitiva del aprendizaje supervisado. El sello distintivo del aprendizaje supervisado es el objetivo de entrenamiento de minimizar el output de divergencia de ella.



Para adaptarse a una noción más versátil de aprendizaje moderna de ML utiliza "supervisión" o "señales" de cualquier fuente fiable.

Aprendizaje autosupervisado

El etiquetado de datos puede resultar prohibitivo para grandes conjuntos de datos. El aprendizaje auto-supervisado en tareas en las que una señal de supervisión se obtiene por lo tanto, "auto" supervisado.

Por ejemplo, los [autocodificadores](#) están entrenados con la entrada y luego reconstruir (o *decodificar*) la entrada comprimida. Su objetivo de entrenamiento es reconstruir la propia entrada original como verdad fundamental. Este es el principal método de entrenamiento para los modelos de muestras de texto con ciertas palabras ocultas para predecir las palabras que faltan.

El aprendizaje autosupervisado se asocia con frecuencia con el aprendizaje profundo que puede proporcionar [modelos fundacionales](#) que se [ajustarán](#) para tareas más específicas.

Aprendizaje semisupervisado

Mientras que el aprendizaje autosupervisado es un aprendizaje no supervisado de datos no etiquetados, los métodos de aprendizaje semisupervisado combinan datos etiquetados como no etiquetados. En términos generales, comprende técnicas que utilizan información de los datos etiquetados para hacer suposiciones sobre los puntos de datos no etiquetados que se incorporan a los flujos de trabajo de aprendizaje.

Aprendizaje no supervisado

Los algoritmos de machine learning no supervisado se aplican a datos no etiquetados, como similitudes, correlaciones y patrones en escenarios en los que dichos patrones no son evidentes para los observadores humanos. Dado que el aprendizaje no supervisado no requiere de supervisión humana, es el tipo de aprendizaje más común.



un output "correcto" conocido, no requiere señales convencionales, de ahí el término "no supervisado".

La mayoría de los métodos de aprendizaje no supervisado tienen las siguientes funciones:

- Los algoritmos de **agrupación** dividen los puntos en agrupaciones, en función de su proximidad. Las tareas como la segmentación del mercado o el análisis de agrupación más destacados se encuentran en los algoritmos de mezcla gaussiana (GMM) y los métodos basados en distancia.
- Los algoritmos de **asociación** distinguen ciertos patrones bajo ciertas condiciones. Por ejemplo, las empresas de comercio electrónico utilizan modelos de **asociación** no supervisados para la recomendación de productos.
- Los algoritmos de **reducción de dimensionalidad** reducen los datos al representarlos con un número menor de dimensiones, al tiempo que **conservan sus características principales** para el preprocesamiento de datos, la visualización de datos. Entre los algoritmos más destacados se encuentran los **autocodificadores** (PCA), el **análisis discriminante lineal** (LDA) y **distribuidos en t** (t-SNE).

Como su nombre indica, los algoritmos de aprendizaje no supervisado no requieren términos generales como algo que "se optimiza". En su lugar, demuestra cómo un algoritmo de agrupación encuentra el centroide de cada clúster por sí solo. Por lo tanto, los algoritmos no supervisados se centra en el preprocesamiento de datos, como **los hiperparámetros** que influyen en el proceso de aprendizaje, como la **tasa de aprendizaje**.

Aprendizaje por refuerzo

Mientras que el aprendizaje supervisado entrena a los modelos con ejemplos ideales y los algoritmos de aprendizaje no supervisado reducen los datos, los **modelos de aprendizaje por refuerzo** aprenden a través del ensayo y error. Se utilizan de forma destacada en los juegos de estrategia, el **razonamiento** y otros casos de uso en los que el agente aprende a través de la experiencia.



especialmente amplio, abierto o difícil de definir. Una referencia a un sistema de IA como un "agente"

En lugar de los pares independientes de datos como en el aprendizaje supervisado, el aprendizaje por refuerzo (RL) funciona como un aprendizaje de estado-acción-recompensa. En lugar de minimizar la pérdida, el aprendizaje por refuerzo es optimizar los parámetros para maximizar la recompensa.

Un marco matemático para el aprendizaje por refuerzo consta de los siguientes componentes:

- El **espacio de estado** contiene toda la información que pueda tomar el modelo. El estado suele ser una representación del modelo.
- El **espacio de acción** contiene todas las decisiones que el agente puede tomar en un momento dado. En un juego de mesa, por ejemplo, los movimientos legales disponibles en un momento dado. El espacio de acción comprende todo el "vocabulario" de acciones.
- La **señal de recompensa** es el feedback—por ejemplo, un valor escalar proporcionado al agente que indica si la acción fue buena o mala. La señal de recompensa podría determinarse mediante una *función de recompensa* o mediante un *modelo de recompensa*.
- Una **política** es el "proceso de pensamiento" que el agente utiliza para elegir una acción. Matemáticamente hablando, una política toma como entrada un estado y devuelve una acción (a): π

En los métodos de RL basados en políticas, como el aprendizaje por refuerzo directo, el modelo aprende una política directamente. En el aprendizaje por refuerzo basado en valores, el agente aprende una función de valor para cada estado y, a continuación, elige la acción que maximiza el valor. Considere un laberinto: un agente basado en políticas puede aprender a moverse desde la izquierda hacia la derecha, mientras que un agente basado en valores puede aprender a moverse desde una posición y simplemente se mueve a una posición que maximice el valor. Los enfoques híbridos, como los métodos actor-crítico, se utilizan para optimizar una política.


En el aprendizaje por refuerzo profundo, la política



Deep learning

El **deep learning** emplea **redes neuronales artifi** "deep", que significa "profundo"), en lugar de lo machine learning tradicional. Aunque las redes historia del machine learning, no fue hasta final 2010, gracias en parte a los avances en las **GPU** mayoría de los subcampos de la IA.

Inspiradas libremente en el cerebro humano, la interconectadas de "neuronas" (o *nodos*), cada de activación. La activación de cada nodo sirve capa siguiente y así sucesivamente hasta la cap red. Las funciones de activación que se realizan *lineales*, lo que permite a las redes neuronales



A cada conexión entre dos neuronas se le asigna un peso, que puede aumentar o disminuir la contribución de una neurona a la siguiente. Junto con los términos *de sesgo* únicos añadidos a cada capa, los pesos y los sesgos son los parámetros que se optimizarán mediante el algoritmo de retropropagación.

El algoritmo **de retropropagación** permite calcular la salida general de la función de pérdida, lo que permite ajustar millones o miles de millones de ponderaciones **de gradiente**. Debido al volumen y la granularidad de los datos, lograr resultados óptimos, el deep learning requiere una gran cantidad de recursos computacionales.

recursos computacionales en comparación con


Esa estructura distribuida proporciona a los modelos una gran versatilidad. Imagine los datos de entrenamiento como un gráfico bidimensional. Esencialmente, el machine learning trata de encontrar una única curva que recorra cada uno de los puntos. Un número arbitrario de líneas más pequeñas y más complejas en forma deseada. Las redes neuronales son *aproximadamente* teóricamente que para cualquier función, existe una que puede reproducirla.^{3, 4}

Dicho esto, el hecho de que algo sea *teóricamente posible* no es práctico mediante los métodos de entrenamiento actuales. El rendimiento adecuado en ciertas tareas estuvo limitado. Con el deep learning, pero con el tiempo, las modificaciones han desbloqueado nuevas capacidades para los modelos.

Redes neuronales convolucionales


Las **redes neuronales convolucionales (CNN)** son un tipo de redes neuronales. En matemáticas, una convolución es una operación que modifica (o *convoluciona*) la forma de otra. En el machine learning, se utiliza para extraer características importantes de los datos, que se asocian principalmente con modelos de visión por computadora, pero un número de otros casos de uso importantes.





Redes neuronales recurre

Las **redes neuronales recurrentes (RNN)** están diseñadas para procesar datos secuenciales. Mientras que las redes neuronales convolucionales asignan un único output, las RNN asignan una *secuencia* recurrente en el que el output de un paso determina la entrada para el cálculo del siguiente paso. En este contexto, se llama *estado oculto*, que permite a las RNN



Transformadores

Los [modelos de transformadores](#), introducidos responsables de la llegada de los LLM y otros pilares de vanguardia en la mayoría de los subdominios, los transformadores están aparentemente diseñados para proporcionar soluciones inteligentes han permitido que la mayoría de las tareas sean procesadas por transformadores. La fuerza única de su innovador [mecanismo de atención](#), que permite

en las partes de los datos de entrada más relevantes de la secuencia.

Modelos Mamba

Los [modelos Mamba](#) son una arquitectura de red neuronal introducida por primera vez en 2023, basada en el [espacio de estados \(SSM\)](#). Al igual que los transformadores, es un medio innovador para priorizar selectivamente la información en un momento dado. Mamba ha surgido recientemente como un nuevo tipo de transformadores, especialmente para los LLM.

Casos de uso de machine learning

La mayoría de las aplicaciones de machine learning se dividen en las siguientes categorías, que se definen principalmente por los tipos de datos con las que operan.

Visión artificial

La visión artificial es el subdominio de la IA relacionado con el procesamiento de otras modalidades de datos que requieren un análisis de imágenes, como diagnósticos sanitarios hasta reconocimiento facial. Los casos de uso notables de la visión artificial incluyen la clasificación de imágenes, la [segmentación de imágenes](#) y el [reconocimiento de objetos](#).

Procesamiento del lenguaje natural

El campo del [procesamiento del lenguaje natural](#) se centra en las tareas relacionadas con el texto, el habla y otros datos lingüísticos. Los casos de uso incluyen los [chatbots](#), el [reconocimiento de voz](#), el [análisis de sentimientos](#), la [generación de texto](#), la [elaboración de lenguaje natural \(PLN\)](#) moderno, los modelos de lenguaje de gran escala y los modelos de lenguaje de gran escala anteriores.

Análisis de series temporales

Los [modelos de series temporales](#) se aplican a la predicción del mercado y reconocimiento de patrones o predicción de eventos futuros.



en datos históricos para diversos casos de uso (

Generación de imágenes

Los modelos de difusión, los autocodificadores antagónicas (GAN) se pueden utilizar para generar imágenes de píxeles aprendidos de los datos de entrenamiento.

Mixture of Experts | 12 de diciembre, episodio 85



Descifrar la IA: resumen semanal

Únase a nuestro panel de ingenieros, investigadores, producto y otros profesionales de talla mundial para el bullicio de la IA para ofrecerle las últimas noticias y perspectivas.

[Vea todos los episodios de Mixture of Experts](#)



Operaciones de machine learning (MLOps)

Las operaciones de machine learning (MLOps) son un enfoque de línea de montaje para crear, implementar y mantener machine learning.

La curación y preprocesamiento cuidadosos de la selección adecuada del modelo, son pasos cruciales posteriores al entrenamiento, desde el monitoreo hasta la priorización de métricas de rendimiento. Asegurar que un modelo generalice bien (y no solo sobreajuste) es esencial.

Tras la implementación, los modelos deben monitorearse para problemas de eficiencia de inferencia y otros de rendimiento. El gobierno de modelos es esencial para la eficacia en entornos regulados o que cambian rápidamente.

Bibliotecas de machine learning

Existen varias herramientas, bibliotecas y marcos para probar proyectos de machine learning. Si bien existen módulos y abstracciones preconfigurados para flujos de trabajo basados en ML y flujos de trabajo, los profesionales de programación de uso común, particularmente en entornos de producción, a menudo necesitan más control.

Entre las principales bibliotecas de código abierto de machine learning, se incluyen PyTorch, TensorFlow, Keras y otros.

Entre las bibliotecas y kits de herramientas de machine learning destacados centrados en el ML tradicional se incluyen Matplotlib, SciPy y NumPy, entre muchos otros.

La propia IBM mantiene y actualiza una importante colección de herramientas para principiantes como para profesionales avanzados.



Ebook

Ciencia de datos y MLOps para líderes de datos

Únase a otros líderes para impulsar los tres pilares esenciales del MLOps y la IA fiable: confianza en los datos, confianza en los modelos y confianza en los procesos.

[Lea el ebook](#)



Recursos

Formación

Amplíe sus conocimientos de ML

Aprenda los conceptos fundamentales y desarrolle sus habilidades con laboratorios prácticos, cursos, proyectos guiados, pruebas y mucho más.

[Explore cursos de ML](#)



Ebook

Desbloquee el poder de la IA generativa + ML

Aprenda a incorporar con confianza la IA generativa y el machine learning a su negocio.

[Lea el ebook](#)



Pódcast de Techsplainers

Explicación del machine learning

Techsplainers de IBM desglosa los fundamentos del machine learning, desde los conceptos clave hasta los casos de uso del mundo real. Los episodios claros y rápidos le ayudan a aprender los fundamentos rápidamente.

[Escuche ahora](#)



Guía

Ponga la IA a trabajar: cómo impulsar el ROI con la IA generativa

¿Quiere obtener un mayor rendimiento de sus inversiones en IA? Descubra cómo escalar la IA generativa en áreas clave impulsa el cambio ayudando a sus mentes más brillantes a crear y ofrecer nuevas soluciones innovadoras.

Ebook

Cómo elegir el modelo fundacional adecuado

Aprenda a seleccionar el modelo fundacional de IA más adecuado para su caso de uso.

[Lea el ebook](#)



modelos de IA

Explore IBM Granite

IBM® Granite es nuestra familia de modelos de IA abiertos, eficaces y de confianza, adaptados para la empresa y optimizados para escalar sus aplicaciones de IA. Explore las opciones de lenguaje, código, series temporales y límites de protección.


[Conozca Granite](#)




Guía

Cómo prosperar en la era de la IA con seguridad y confianza

Profundice en los tres elementos cruciales de una estrategia de IA sólida: crear una ventaja competitiva, ampliar la IA en toda la empresa y promover una IA fiable.




Soluciones relacionadas



IBM watsonx.ai

Entrene, valide, ajuste e implemente IA generativa, modelos fundacionales y capacidades de machine learning con IBM watsonx.ai, un estudio empresarial de nueva generación para desarrolladores de IA. Cree aplicaciones de IA en menos tiempo y con menos datos.


[Descubra watsonx.ai](#) →



Soluciones de inteligencia artificial

Ponga la IA a trabajar en su negocio con la experiencia líder en IA del sector de IBM y junto a su cartera de soluciones.

[Explore las soluciones de IA](#) →



Consultoría y servicios de IA

Reinvente las operaciones y flujos de trabajo críticos añadiendo IA para maximizar las experiencias, la toma de decisiones en tiempo real y el valor empresarial.

[Explore los servicios de IA](#) →

Dé el siguiente paso

Obtenga acceso único a capacidades que abarcan el ciclo de vida de desarrollo de la IA. Produzca potentes soluciones de IA con interfaces intuitivas, flujos de trabajo y acceso a API y SDK estándar del sector.

[Explore watsonx.ai](#)

[Solicite una demostración en directo](#) →

Notas a pie de página

Vínculos externos a ibm.com

1. ["Some Studies in machine learning Using the Game of Checkers"](#), *IBM Journal* (acceso a través del MIT), 3 de julio de 1959

2. "Utilización de árboles de decisión como sistema experto de apoyo a la toma de decisiones clínicas para COVID-19, [🔗](#) " *Interactive Journal of Medical Research*, Vol 12, 30 de enero de 2023
3. "Kolmogorov's Mapping Neural Networks Existence Theorem, [🔗](#) " *Proceedings of the IEEE First International Conference on Neural Networks* (acceso a través de la Universidad de Waterloo), 1987
4. "Multilayer Feedforward Networks with a Non-Polynomial Activation Function Can Approximate Any Function, [🔗](#) " Centro de Investigación en Sistemas de Información (Universidad de Nueva York), marzo de 1992